

SomnoScope

Arturo Molina
Catalina García
Daniel Franco
Nicolás Gómez



SomnoScope

Clasificación automática de estadios de sueño a partir de EEG de un solo canal, como línea base hacia una plataforma de estadificación de sueño más completa

Problema y contexto

El sueño desempeña un papel central en la salud humana: su alteración se asocia con enfermedades cardiovasculares, neurológicas, psiquiátricas y metabólicas, además de afectar el desempeño cognitivo y la calidad de vida. El examen de referencia para su estudio es la polisomnografía (PSG), que registra simultáneamente señales como la electroencefalografía (EEG), la electrooculografía (EOG) y la electromiografía (EMG) durante una noche completa. A partir de esas señales, un técnico certificado clasifica manualmente cada segmento de 30 segundos (época) en uno de los estadios definidos por la Academia Americana de Medicina del Sueño (AASM): vigilia (W), N1, N2, N3 y REM — un proceso que puede implicar revisar entre 800 y 1200 épocas por paciente, es lento, costoso y presenta variabilidad entre evaluadores, especialmente en estadios de transición como N1.

Este microproyecto aborda una versión acotada de ese problema: entrenar un modelo de clasificación de estadios de sueño a partir de un único canal de EEG (Fpz-Cz), usando un enfoque clásico de aprendizaje de máquina (extracción de características espectrales/estadísticas + Random Forest), en lugar de arquitecturas de aprendizaje profundo como las reportadas en la literatura (DeepSleepNet, TinySleepNet, U-Sleep). El objetivo no es competir con esas arquitecturas, sino construir la línea base metodológica —datos versionados, pipeline de extracción de características, modelo empaquetado, API y tablero de experimentación— sobre la cual se apoyará un desarrollo posterior más avanzado (multicanal, deep learning) enmarcado en un proyecto de grado de la Maestría en Inteligencia Artificial.

Pregunta de negocio

¿Cómo reducir el tiempo de diagnóstico en el análisis de polisomnografías mediante la clasificación automática de los estadios del sueño con aprendizaje de máquina?

Esta pregunta surge por la necesidad de agilizar el diagnóstico clínico actual. Hoy en día, un especialista debe etiquetar manualmente registros de EEG de 8 horas divididos en miles de épocas de 30 segundos, lo que toma entre 2 y 4 horas por paciente. El uso de aprendizaje de máquina busca eliminar este cuello de botella, automatizando la clasificación para reducir drásticamente el tiempo invertido por examen.

Alcance del proyecto

Con fines académicos y de investigación:

1. Datos: se limita al uso de la base de datos pública Sleep-EDF Expanded, utilizando aproximadamente 197 registros nocturnos. Se procesarán los canales de EEG (Fpz-Cz y Pz-Oz) y, de estar disponibles, señales complementarias de EOG y EMG, segmentadas en épocas de 30 segundos. Las etiquetas se adaptarán a cinco estadios (W, N1, N2, N3 y REM), descartando o tratando las marcas de movimiento (M) o indefinidas (?).
2. Modelo: se limita al desarrollo y comparación de algoritmos para clasificar las cinco fases del sueño. Se evaluarán enfoques tradicionales basados en características estadísticas (como Random Forest o LightGBM) frente a redes de aprendizaje profundo (como CNN 1D o TinySleepNet). El desempeño se medirá mediante exactitud global, F1-score macro y matrices de confusión, con énfasis en la clase minoritaria N1, contrastando los resultados únicamente con la literatura que use la misma base de datos.
3. Prototipo: se limita al desarrollo de una plataforma funcional que permita cargar registros de señales fisiológicas y visualizar la clasificación automática del sueño. El sistema exigirá como requisito mínimo al menos un canal de EEG (Fpz-Cz o Pz-Oz), permitiendo opcionalmente incorporar señales de EOG y EMG para evaluar la robustez del modelo ante diferentes combinaciones de entrada. Finalmente, se medirá la utilidad del software analizando su capacidad para reducir el tiempo de revisión manual y mitigar la variabilidad entre evaluadores, operando estrictamente como una herramienta de apoyo y no como un sistema de diagnóstico médico certificado.
4. Limitaciones: el software se desarrollará a nivel de prototipo experimental y funcionará estrictamente como una herramienta de apoyo al análisis; por lo tanto, queda fuera del alcance emitir diagnósticos médicos automáticos, detectar trastornos específicos del sueño o cumplir con las certificaciones regulatorias exigidas para sistemas de uso clínico institucional.
5. Resultados esperados: la entrega de un modelo optimizado de aprendizaje de máquina con métricas competitivas de exactitud y F1-score (especialmente en la fase N1), un estudio comparativo documentado entre enfoques tradicionales y de aprendizaje profundo, y un prototipo funcional de plataforma que procese de forma multicanal las señales. Finalmente, se espera demostrar conceptualmente una reducción significativa en el tiempo de revisión y una menor variabilidad en el etiquetado de los estadios del sueño en comparación con el método manual tradicional.

Descripción de conjuntos de datos

Para el desarrollo de este proyecto se utilizará el Sleep-EDF Database Expanded (Sleep-EDFx), un conjunto de datos de acceso público disponible en PhysioNet ([Sleep-EDF Database Expanded](https://physionet.org/files/sleep/edsdb/expanded/)).

Repositorio: <https://github.com/Nicolasdgg/MicroPIMAIA>

El conjunto contiene aproximadamente 197 estudios de sueño, divididos en dos subconjuntos:

- **Sleep Cassette (SC):** 153 registros de estudios de sueño en casa de sujetos sanos de 25-101 años, obtenidos en un estudio sobre los efectos de la edad en el sueño.
- **Sleep Telemetry (ST):** 44 registros de sujetos con leves dificultades para dormir tratados con temazepam.

Cada registro incluye:

- Al menos dos canales de EEG (Fpz-Cz y Pz-Oz), muestreados a 100 Hz.
- Un canal de EOG (electrooculografía) horizontal.
- Un canal de EMG submentoniano (en la mayoría de los registros).
- Un hipnograma anotado manualmente por técnicos expertos según el manual Rechtschaffen & Kales, que servirá como etiqueta (ground truth) para el entrenamiento y evaluación de los modelos.

Cada noche de registro dura entre 20 y 24 horas aproximadamente, segmentada en épocas de 30 segundos, lo que da un total estimado de 800 a 1,200 épocas etiquetadas por sujeto.

Exploración inicial de los datos (EDA)

Objetivo de la exploración de los datos

El objetivo de este análisis exploratorio es caracterizar la estructura, dimensionalidad y distribución del conjunto de datos Sleep-EDFx para el desarrollo de un sistema de clasificación automática de estadios de sueño. Este análisis permite verificar la integridad de las señales de polisomnografía (PSG), estandarizar las anotaciones clínicas hacia el estándar moderno AASM, evaluar el balance de clases y definir las pautas críticas de partición de datos y preprocesamiento que guiarán el modelado de Machine Learning.

Alcance y estructura de los datos analizados

El dataset público Sleep-EDFx (PhysioNet) contiene registros de polisomnografía de noche completa organizados en dos cohortes: * Sleep-Cassette (SC): 153 registros ambulatorios de aproximadamente 24 horas continuas en sujetos sanos (21 a 101 años) en su entorno habitual sin medicación. * Sleep-Telemetry (ST): 44 registros hospitalarios nocturnos (alrededor de 8 a 9 horas) en pacientes con dificultad moderada para conciliar el sueño. A continuación se resume la estructura técnica y dimensionalidad de los datos:

Atributo / Canal	Especificación Técnica
Formato de Archivos	European Data Format (EDF de 16 bits) para señales (*PSG.edf) y anotaciones (*Hypnogram.edf)
Canales Electroencefalográficos (EEG)	EEG Fpz-Cz y EEG Pz-Oz muestreados a 100 Hz (amplitud en microvoltios, μV)
Canales Complementarios (EOG / EMG)	EOG horizontal (100 Hz) y EMG submentoniano (100 Hz / envolvente muscular)
Canales Adicionales	Flujo respiratorio oro-nasal (1 Hz), Temperatura rectal (1 Hz) y Marcadores de eventos
Segmentación de Señal	Ventanas continuas de 30 segundos (3,000 muestras por época a 100 Hz)

Estandarización de Anotaciones al Estándar AASM (5 Clases)

Las anotaciones clínicas originales siguen el manual clásico de Rechtschaffen & Kales (R&K). Para el entrenamiento de modelos modernos, se realizó un mapeo estandarizado hacia las 5 clases recomendadas por la Academia Americana de Medicina del Sueño (AASM):

Etiqueta Original (R&K)	Clase AASM	Descripción Fisiológica
Sleep stage W	W	Vigilia activa o relajada con ritmo alfa posterior (8–12 Hz)
Sleep stage 1	N1	Sueño ligero de transición (desincronización, ondas de vértex)
Sleep stage 2	N2	Sueño ligero consolidado con presencia de husos de sueño y complejos K
Sleep stage 3 / Stage 4	N3	Sueño profundo de ondas lentas delta (Slow Wave Sleep - SWS, $>75 \mu V$)
Sleep stage R	REM	Sueño paradójico (movimientos oculares rápidos con atonía muscular)
Movement time / Stage ?	Descarte (M / ?)	Épocas con artefactos severos de movimiento o pérdida de señal

Balance de Clases y Composición del Sueño

El análisis sobre la muestra procesada (37,194 épocas de 30 segundos) evidencia dos aspectos centrales: 1. Desbalance Severo en N1: El estadio N1 representa únicamente el 3.4% ($n = 1,284$) del total de épocas, siendo la clase minoritaria crítica. En contraparte, N2 constituye la etapa mayoritaria de sueño (23.9%, $n = 8,889$), seguido por REM (8.4%, $n = 3,116$) y N3 (6.0%, $n = 2,248$). 2. Estructura de Vigilia según Cohorte: En Sleep-Cassette, la vigilia (W) abarca el 58.3% ($n = 21,657$) debido al registro extendido de 24 horas (incluyendo vigilia

diurna antes y después de dormir). En Sleep-Telemetry, al iniciar la grabación en cama, la vigilia se reduce a <10% y la eficiencia de sueño supera el 90%.





Figura 1: (A) Distribución global de épocas según estándar AASM, evidenciando el desbalance de la clase N1. (B) Composición nocturna individual por sujeto, contrastando grabaciones de 24 horas (SC) frente a registros hospitalarios (ST).

Licencia y Uso Ético

El conjunto de datos Sleep-EDFx es distribuido por PhysioNet bajo licencia abierta ODC Public Domain Dedication and License (PDDL). Los registros fueron totalmente anonimizados en origen, no contienen datos personales identificables y su uso está autorizado para fines académicos y de investigación sin restricciones.

Maqueta del prototipo



Descripción de la interfaz: se diseñó una maqueta navegable (HTML) del tablero, “SomnoScope”, que representa la interacción principal entre el usuario y el sistema: cargar un registro de polisomnografía y revisar la estadificación de sueño generada por el modelo frente a la anotación experta, junto con las métricas de desempeño que exige la propuesta de proyecto de grado (accuracy, F1-macro, matriz de confusión).

Elementos clave:

Barra superior: carga de registro EDF y selector de sujeto/noche.

Panel de contexto: duración del registro, número de épocas, canal de entrada verificado (EEG Fpz-Cz) y chips de calidad de datos (épocas “M”/“?” excluidas), para no ocultar problemas de calidad de los datos frente al usuario.

Hipnograma de la noche: franja de estadios predichos vs. franja de anotación real (cuando está disponible), con tooltip por época.

Matriz de confusión y F1-score por clase, para evaluar el modelo con las métricas que la literatura de referencia reporta (macro-F1 por el desbalance de clases minoritarias como N1).

Tabla comparativa de corridas de MLflow, para dar seguimiento a los experimentos con distintas versiones del modelo.

Aviso visible de que se trata de una maqueta con datos de ejemplo, sin conexión real a la API.


Repositorios del código y de los datos

Repositorio GitHub: <https://github.com/Nicolasdgg/MicroP1MAIA>

Versionamiento de datos (DVC / almacenamiento remoto):

Infraestructura utilizada: Github - AWS E2C

Con el objetivo de llevar de forma estructurada y organizada el versionamiento y control de los datos se creó el siguiente repositorio en Github y se desplegó la una maquina virtual usando la plataforma AWS- E2C con las siguientes características:



Creación de repositorio Git y DVC:

```
(env-dvc) ubuntu@ip-172-31-6-152:~$ git --version
git version 2.43.0
(env-dvc) ubuntu@ip-172-31-6-152:~$ cd ~
mkdir dvc-proj
(env-dvc) ubuntu@ip-172-31-6-152:~$ cd dvc-proj
git init
hint: Using 'master' as the name for the initial branch. This default branch name
hint: is subject to change. To configure the initial branch name to use in all
hint: of your new repositories, which will suppress this warning, call:
hint:     git config --global init.defaultBranch <name>
hint:
hint: Names commonly chosen instead of 'master' are 'main', 'trunk' and
hint: 'development'. The just-created branch can be renamed via this command:
hint:     git branch -m <name>
Initialized empty Git repository in /home/ubuntu/dvc-proj/.git/
(env-dvc) ubuntu@ip-172-31-6-152:~/dvc-proj$ git branch -m main
(env-dvc) ubuntu@ip-172-31-6-152:~/dvc-proj$ git branch
(env-dvc) ubuntu@ip-172-31-6-152:~/dvc-proj$ dvc init
Initialized DVC repository.
```

```
(env-dvc) ubuntu@ip-172-31-6-152:~/dvc-proj$ git status
On branch main

No commits yet

Changes to be committed:
  (use "git rm --cached <file>..." to unstage)
        new file:   .dvc/.gitignore
        new file:   .dvc/config
        new file:   .dvcignore
```

```
(env-dvc) ubuntu@ip-172-31-6-152:~/dvc-proj$ ls -la data
total 16
drwxrwxr-x 4 ubuntu ubuntu 4096 Aug 22 16:51 .
drwxrwxr-x 5 ubuntu ubuntu 4096 Aug 22 16:51 ..
drwxrwxr-x 2 ubuntu ubuntu 4096 Aug 22 16:51 processed
drwxrwxr-x 4 ubuntu ubuntu 4096 Aug 22 16:51 raw
(env-dvc) ubuntu@ip-172-31-6-152:~/dvc-proj$ ls -la
total 24
drwxrwxr-x 5 ubuntu ubuntu 4096 Aug 22 16:51 .
drwxr-x--- 6 ubuntu ubuntu 4096 Aug 22 15:18 ..
drwxrwxr-x 3 ubuntu ubuntu 4096 Aug 22 15:20 .dvc
-rw-rw-r-- 1 ubuntu ubuntu 139 Aug 22 15:20 .dvcignore
drwxrwxr-x 8 ubuntu ubuntu 4096 Aug 22 15:30 .git
drwxrwxr-x 4 ubuntu ubuntu 4096 Aug 22 16:51 data
(env-dvc) ubuntu@ip-172-31-6-152:~/dvc-proj$
```

Push DVC a repositorio Remoto:

Para realizar el envío de archivo DVC inicialmente se descargó data de microproyecto desde repositorio remoto y se volvió a hacer push y merge en branch main:


```
(env-dvc) ubuntu@ip-172-31-6-152:~/dvc-proj$ git push -u origin main
Username for 'https://github.com': catagarci
Password for 'https://catagarci@github.com':
Enumerating objects: 15, done.
Counting objects: 100% (15/15), done.
Delta compression using up to 2 threads
Compressing objects: 100% (10/10), done.
Writing objects: 100% (13/13), 1.69 KiB | 1.69 MiB/s, done.
Total 13 (delta 2), reused 0 (delta 0), pack-reused 0
remote: Resolving deltas: 100% (2/2), done.
To https://github.com/Nicolasdgg/MicroP1MAIA.git
   f45ad00..6c35247  main -> main
branch 'main' set up to track 'origin/main'.
```

Instalación S3:

```
No VM guests are running outdated hypervisor (qemu) binaries on this host.
ubuntu@ip-172-31-6-152:~$ python3 -m venv /home/ubuntu/env-dvc
ubuntu@ip-172-31-6-152:~$ source /home/ubuntu/env-dvc/bin/activate
(env-dvc) ubuntu@ip-172-31-6-152:~$ pip install "dvc[s3]"
Collecting dvc[s3]
```

Conexión con S3:

```
(env-dvc) ubuntu@ip-172-31-6-152:~/dvc-proj$ aws s3 mb s3://microproyecto-maia
make_bucket: microproyecto-maia
(env-dvc) ubuntu@ip-172-31-6-152:~/dvc-proj$ dvc remote add -d aws-remote s3://microproyecto-maia
Setting 'aws-remote' as a default remote.
```

The screenshot shows the GitHub repository page for 'MicroP1MAIA', which is public. The repository has 6 branches, 0 tags, and 11 commits. The commit history is listed as follows:

Commit	Message	Time
6c35247	Integrar DVC con repositorio existente	19 minutes ago
6c35247	Adicionar S3 como remote	1 minute ago
6c35247	docs: actualizar REPORTE.docx y agregar conjunto de datos ...	1 hour ago
6c35247	Inicializacion de DVC	2 hours ago
6c35247	Integrar DVC con repositorio existente	19 minutes ago
6c35247	docs: actualizar REPORTE.docx y agregar conjunto de datos ...	1 hour ago
6c35247	agregar problema de negocio y primera version de la maqu...	16 hours ago
6c35247	Primera version de los datos	45 minutes ago
6c35247	agregar problema de negocio y primera version de la maqu...	16 hours ago
6c35247	agregar problema de negocio y primera version de la maqu...	16 hours ago

The repository files include .dvc, data, .dvcignore, .gitignore, REPORTE.docx, REPORTE.pdf, data.dvc, maqueta_dashboard.html, and maqueta_screenshot.png. The right sidebar shows the repository's activity, including 0 stars, 0 watching, and 0 forks. The 'About' section describes the project as 'Espacio para elaborar el micro proyecto # 1 para la maestría de inteligencia artificial.' The 'Releases' section shows no releases published, and the 'Packages' section shows no packages published.

Buckets

Buckets de uso general

Todas las regiones de AWS

Buckets de directorio

Buckets de uso general (2) Información

Copiar ARN

Vaciar

Eliminar

Crear bucket

Los buckets son contenedores de datos almacenados en S3.

Q

Buscar buckets por nombre

<

1

>

Nombre	Región de AWS	Fecha de creación
catalinag-dvcstore	Este de EE. UU. (Norte de Virginia) us-east-1	17 Aug 2026 9:49:07 PM -05
microproyecto-maia	Este de EE. UU. (Norte de Virginia) us-east-1	22 Aug 2026 12:42:56 PM -05

Colaboradores y tareas específicas

Tarea	Responsable(s)
Problema que abordaran y contexto	Nicolas Gomez
Pregunta de negocio y alcance de proyecto	Catalina Garcia
Conjunto de datos a usar	Daniel Franco
Repositorio Git en uso	Todos
Repositorio DVC en uso	Todos
Exploración de datos	Arturo Molina
Maqueta del prototipo	Nicolas Gomez

Referencias

1. B Kemp, AH Zwinderman, B Tuk, HAC Kamphuisen, JJL Oberyé. Analysis of a sleep-dependent neuronal feedback loop: the slow-wave microcontinuity of the EEG. IEEE-BME 47(9):1185-1194 (2000).
2. Pollard, T., Moody, B. E., Lehman, L., Gow, B., Fernandes, C., Xie, C., Johnson, A., Mark, R. G., & Heldt, T. (2026). PhysioNet as a global platform for biomedical research. Nature Health. <https://doi.org/10.1038/s44360-026-00096-z>. Available from: <https://rdcu.be/faatM>